Relatório v2: um sistema de classificação sem modelo de linguagem na decisão

> **Em resumo.** 125 das 559 Questões avaliadas (22%) vão direto ao aluno. Prevejo que 97 em cada 100 delas estejam certas (intervalo de 0,76 a 1,00). Quem decide é um Ranqueador treinado nas 100 Questões da equipe. Nenhum modelo de linguagem escolhe, vota ou valida o Tema, e `uv run classificacao v2 entrega` regenera os dois arquivos em cerca de um minuto, na CPU, sem rede, com saída idêntica a cada rodada.

a) O sistema, peça por peça

O difícil não é achar um Tema provável: é saber **quando o sistema pode confiar em si mesmo**. Cada peça gera um sinal que ajuda a separar acerto de erro, e a decisão é de um modelo pequeno, calibrado nos exemplos da equipe.

Peça	O que faz	Por que está ali
Limpeza do texto	Mantém só o que o aluno lê	Vem da v1; o lixo do HTML distorce qualquer sinal
Temas enriquecidos	`claude -p` descreveu os 371 Nós (o que entra, o que não entra, termos, leis) **vendo só a Árvore**, com prompt versionado; numa amostra de 30, um segundo modelo propôs 22 correções, revisadas e aceitas pelo autor, e um teste confere contra a Árvore todo caminho citado	333 temas tinham descrição automática ("44 questões no source")
Embeddings locais	Vetores das Questões e dos Temas, gerados uma vez na CPU e versionados	Similaridade de assunto, sem custo nem cota
Leis citadas	Número ou apelido, com um dicionário de 29 leis	A lei diz o assunto; certa em 9 de 13 exemplos
Origem → Nó	O assunto do site casado com o título de um Nó	Sinal fraco: certo em 22 de 92 exemplos
Vizinhas	As 5 Questões rotuladas mais parecidas votam pela Régua	Ensinam a **convenção da equipe**
Candidatos	Top-10 por similaridade, mais leis, Origem, vizinhas e o pai de cada Subtema	O Gabarito está entre eles em 90 de 92 exemplos
Ranqueador por Ramo	Regressão logística com 11 sinais estima a chance de cada Candidato **ser o Gabarito**; cada Nó é pontuado pela soma das chances do seu Ramo	Pela Régua, o Tema pai acerta qualquer Subtema; a dúvida entre irmãos sobe para ele sem regra especial
Decisão	Publica acima do limiar; Tema duplicado só com exemplo da equipe; Direito Penal Militar é Fora	Regras curtas e testadas

O que testei e descartei. A métrica é a da Régua: publicadas e acertos fora do fold no limiar de maior cobertura com taxa suavizada ≥ 0,96.

Ranqueador	bge-m3: top-1	bge-m3: publicadas	e5-base: top-1	e5-base: publicadas
Similaridade pura	0,59	0	0,57	0
kNN na Folha-verdade	0,31	0	0,26	0
Regressão logística ("certo pela Régua")	0,63	0	0,69	0

Ranqueador	bge-m3: top-1	bge-m3: publicadas	e5-base: top-1	e5-base: publicadas
MLP pequeno	0,58	0	0,68	0
Logística por massa do Ramo	0,67	**28 de 28**	0,73	0
Por Ramo, sem a Origem	0,66	27 de 27	0,74	0

O e5-base acerta mais no top-1, mas espalha os erros pelo topo da lista. O que a Régua exige é um topo limpo, e é aí que o bge-m3 por Ramo ganha. Também descartei: sinais extras da hierarquia (aumentam o top-1, mas puxam um erro para a 17ª posição); votos dos LLMs da v1 (seriam um modelo de linguagem votando por tabela); embeddings por API (cota e custo).

b) Os 100 rótulos

Como usei. Todos em validação cruzada estratificada (10 folds, por disciplina e Fora), sem holdout: com 371 Nós, separar 30 deixaria o treino pobre e o teste ainda mais incerto. Cada Questão foi pontuada por um Ranqueador que não a viu, e o kNN só via as Questões de treino do fold. Essas pontuações escolheram o Ranqueador, o limiar e a confiança, e são a base da previsão.

O que mostraram sobre o sistema. As 28 Questões de pontuação mais alta estão todas certas. Depois, os erros aparecem logo. Esse é o limite do que 100 rótulos provam: o limite inferior de Wilson ≥ 0,95 exigiria 73 acertos sem erro, e mesmo o alvo de 0,97 exigiria 32. Por isso o alvo é a taxa suavizada ≥ 0,96, com o intervalo largo declarado (ADR 0008). Sem a Origem, o resultado quase não muda (27 de 27), o que importa porque as Questões novas quase não têm Origem útil.

O que mostraram sobre a convenção da equipe

- **Fora é mais amplo do que parece.** 8 de 100 são Fora, inclusive questões sobre fixação da pena. Os dois erros mais confiantes do sistema são esses. A v1, com dois LLMs votando, publicou 4 deles e ficou em 0,90 na Folha-verdade.
- **Execução penal vai para a LEP**, quase sempre em Legislação Especial (4 vezes contra 1 em Processo Penal).
- **Os exemplos cobrem 61 dos 371 Nós.** Nos outros, quem decide é o Tema enriquecido.
- **Os 100 são antigos (Q0001–Q0359).** A Origem vira Nó em 59% das antigas e em 19% das novas.

c) Diagnóstico

Nos temas. Oito temas existem em duas disciplinas, e um nono tem título com erro de digitação ("Estaturo de Idoso"), por isso nem é reconhecido como duplicado. 333 descrições são automáticas, e a contagem que trazem empurra para as Lixeiras ("Teoria da Pena", 453; "Sistemas e Princípios Processuais Penais", 538). Fatias de apostila ("Teoria da Pena (Parte 1)") viraram Nós.

Nas questões. A Origem engana (a Q0016 vem como Constitucional e é sobre prisão) e traz disciplinas fora da árvore (Penal Militar). 94 Questões não têm comando.

O que o sistema ainda erra (os 33 erros do top-1 fora do fold)

Tipo	Exemplos	O que resolveria
Fora pela equipe, posto num Tema genérico	Q0043 e Q0252, em "Teoria da Pena"	O critério de Fora da equipe (pedido ao Professor) e mais exemplos de Fora

Tipo	Exemplos	O que resolveria
Lixeira atrai o específico	LEP e teorias da pena da Criminologia caem em "Teoria da Pena"	Descrição do Tema aprovada pelo Professor; mais exemplos de LEP
Homônimos entre disciplinas	Tráfico, LEP, Juizado, Estatuto do Idoso	Decidir o lado de cada um (memo)
Contexto diferente do assunto	Q0316 e Q0202: o enunciado fala do crime, o tema é Erro de Tipo	Exemplos rotulados desse padrão
Temas vizinhos	Provas em Espécie e Teoria Geral das Provas; Sentença e Recursos	Descrições que digam o que não entra (já enriquecidas) e mais exemplos

Os erros de pontuação alta são quase todos dos dois primeiros tipos. Os de pontuação baixa já vão para a fila.

d) Produção: 50 mil questões por semana

Custo e tempo. A decisão roda na CPU: 659 Questões levam ~1 minuto (dominado pela validação cruzada e pelo bootstrap; a decisão em si leva segundos). O embedding de cada Questão nova é local: ~2 s por Questão na CPU de 4 núcleos usada aqui, ou seja, ~28 horas por semana para 50 mil numa máquina comum, ou minutos numa GPU modesta, sem custo por chamada. O enriquecimento só roda quando a árvore muda. **O gargalo é o Professor:** com a cobertura de hoje, ~78% vão para a fila.

Como a correção do Professor vira treino

1. Cada Questão revisada vira um par (Questão, Nó certo) e entra no índice das vizinhas no mesmo dia.
2. **Auditoria semanal às cegas:** 50 publicadas sorteadas. São os únicos rótulos sem viés de seleção, e só eles medem a precisão; a fila só traz as difíceis.
3. A fila é ordenada pela incerteza do Ranqueador (aprendizado ativo), e os Temas sem exemplo entram primeiro.

De quanto em quanto tempo retreinar. Toda semana, porque o treino leva segundos, com o limiar recalibrado na janela das últimas semanas. Com ~200 rótulos auditados, o critério passa ao limite inferior do intervalo (ADR 0008). Há retreino extra quando a árvore muda, quando a auditoria tem 3 erros ou mais em 50 (a publicação automática para), quando os sinais de um lote de importação mudam mais de 5 pontos e quando um Tema recebe o dobro da taxa normal de reportes.

O que faria com mais tempo

1. Mais exemplos de Fora e de Temas sem exemplo, pedidos ao Professor por aprendizado ativo.
2. Validação aninhada para escolher sinais e hiperparâmetros sem otimismo.
3. Ajustar o modelo de embeddings com os rótulos acumulados.

e) Memo ao professor

Assunto: as 659 questões de Penal, Processo Penal, Legislação Especial e Criminologia. O que encontrei, o que recomendo mudar nos temas e cinco pedidos concretos.

O que fiz e o resultado

Montei um sistema que aprende com as **100 questões que a sua equipe classificou**. Ele compara cada questão nova com essas 100, com uma descrição de cada tema e com as leis que ela cita, e só publica quando a chance de acerto, medida nos exemplos da equipe, é alta. **125 das 559 questões avaliadas (22%) vão direto ao aluno**, e as demais vão à sua fila com uma sugestão. Espero que **97 em cada 100 publicadas** estejam certas, e o número real deve ficar entre 76 e 100: com 100 exemplos, não dá para prometer mais do que isso. Nenhum sistema de inteligência artificial escolhe o tema: ele só ajudou a escrever, antes, as descrições dos temas, e revisei uma amostra delas.

O que recomendo mudar nos temas

- **Oito temas existem em duas disciplinas**, como a Lei de Execução Penal em Processo Penal e em Legislação Especial. A equipe usou os dois lados.
- **As descrições não descrevem.** 333 temas dizem só "Subtema de X. N questões". Um parágrafo sobre o que entra e o que não entra em cada tema ajuda a máquina e o aluno. As descrições que geramos estão prontas para o senhor aprovar.
- **Temas genéricos acumulam questões de outros**: "Teoria da Pena", "Introdução ao Estudo do Direito Penal" e "Sistemas e Princípios Processuais Penais".
- **Fatias de apostila viraram temas**, como "Teoria da Pena (Parte 1)" e "(Parte 2)". Elas confundem o aluno e a máquina.

Do que preciso do senhor

1. Decidir o lado de cada tema duplicado (uma vez só, oito decisões). Hoje a regra é publicar no lado que a equipe usou nos exemplos e mandar o resto para a fila.

Tema	Sugestão: fica em	Sai de
Lei de Execução Penal	Legislação Especial	Processo Penal
Ação Penal	Processo Penal	Penal
Tráfico de Drogas, Lei Maria da Penha, Crimes Ambientais, Abuso de Autoridade, Lavagem de Dinheiro e Organizações Criminosas	Legislação Especial	Penal

2. Aprovar as descrições de 30 temas (uma planilha, cerca de 20 minutos). Basta marcar "ok" ou corrigir. Começa pelos duplicados e pelos genéricos.

3. Dizer o que é "fora" para a equipe. Nos exemplos, 8 de 100 são fora, inclusive questões sobre fixação da pena e aplicação da lei penal, que a árvore parece cobrir. Uma frase sobre o critério evita que o sistema publique essas questões.

4. Revisar a fila na ordem que ela chega. As primeiras são as que mais ensinam ao sistema, e cada revisão vira exemplo no mesmo dia.

5. Toda semana, conferir 50 questões publicadas, sorteadas e sem ver a resposta do sistema. Se 3 ou mais estiverem erradas, a publicação automática para até corrigirmos.